Языки ассемблера и двоичный код

Леция №4
АКОС 2019-2020

Стадии трансляции

- Препроцессинг текста; на выходе - текст
- Из исходного текста - Abstract Syntax Tree и таблицы символов; формат - внутренний для реализации компиляторов
- Из AST получаем:
  – либо код на языке ассемблера (текст)
  – либо двоичный код

Языки ассемблера

- Последовательность команд - линейная
- Нет вложенных конструкций
- Не бывает вычислимых выражений (точнее, это syntax sugar)

- Текст распознается регулярным выражением, а не констекстно-свободной грамматикой

Языки ассемблера

- Из AST получаем:
  - либо код на языке ассемблера (текст)
  - либо двоичный код

- Из текста программы можно выделить отдельные фрагменты, которые кодируют бинарные инструкции
- Последовательность бинарных инструкций позволяет восстановить текст на ASM

Кодирование команд

- RISC: одна команда - это машинное слово
  - зная начало кода, можно извлечь любую инструкцию
- CISC: одна команда - это произвольное количество байт
  - нужно прочитать и декодировать несколько байт, чтобы найти следующую команду

Команды и регистры

- Процессор, в общем случае, может выполнять некоторые действия только над значениями регистров
- Регистр - не просто быстрая ячейка памяти, а ячейка, к которой можно обратиться напрямую
- Доступ памяти - достаточно сложная операция
- Но: некоторые процессоры (x86) имеют разные способы адресации, позволяющие адресовать память

Кодирование команд (AVR)

ADD – Add without Carry

Description

Adds two registers without the C Flag and places the result in the destination register Rd.

Operation:

(i) (i) Rd ← Rd + Rr

	Syntax:	Operands:	Program Counter:
(i)	ADD Rd,Rr	0 ≤ d ≤ 31, 0 ≤ r ≤ 31	PC ← PC + 1

16-bit Opcode:

0000	11rd	dddd	rrrr

Кодирование команд (AVR)

LDI – Load Immediate

Description

Loads an 8-bit constant directly to register 16 to 31.

	Operation:		
(i)	Rd ← K		
	Syntax:	Operands:	Program Counter:
(i)	LDI Rd,K	16 ≤ d ≤ 31, 0 ≤ K ≤ 255	PC ← PC + 1

16-bit Opcode:

1110	KKKK	dddd	KKKK

Что нужно закодировать
(или что делает ассемблер)

- Какая именно команда
- С какими регистрами она работает
- Константы:
  - могут встречаться в численных операциях
  - адреса (метки) в инструкциях перехода

Кодирование ARM-32

ADD

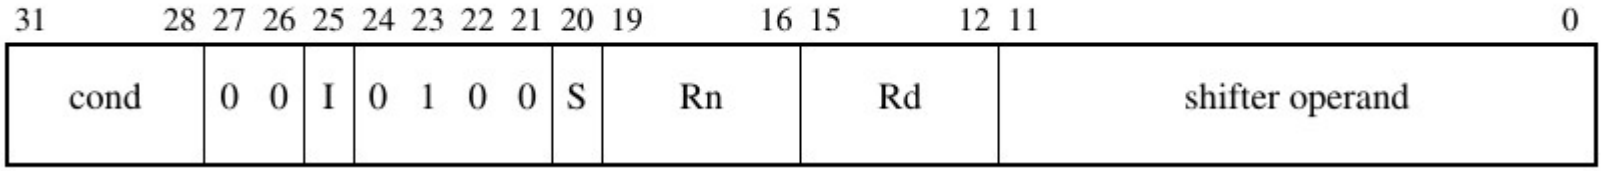

- **cond** - условие выполнения команды
- **I** - флаг, определяющий, что закодировано в **shifter_operand**
- **S** - флаг, определяющий, нужно ли обновлять регистр статуса
- **Rn**, **Rd** - первый аргумент операции и куда записать результат

Примеры:

ADD **r0**, **r1**, **r2** // r0 ← r1 + r2
ADD**S** **r0**, **r1**, **r2** // r0 ← r1 + r2, обновить флаги Z,V,C,N
ADD**EQ** **r0**, **r1**, **r2** // Если Z, то r0 ← r1 + r2
ADD **r0**, **r1**, **r2, lsl #3** // r0 ← r1 + (r2 << 3) [5bit shift; 2bit type; 0; 4bit reg]
ADD **r0**, **r1**, **#0xFF** // r0 ← r1 + 0b0000'1111'1111
ADD **r0**, **r1**, **#0x200** // r0 ← r1 + (0b0000'0010 ROR 0b1100)

Ключевая проблема

Нельзя впихать невпихуемое

- Длина команды - 32 бит
- Часть из них заняты OPcode и номерами регистров

Циклический сдвиг констант (ARM)

- Под константы зарезервировано 12 бит
- 8 бит - значение
- 4 бит - сдвиг со вращением

Циклический сдвиг констант (ARM)

```
  255 = 0xFF ROR 0
  256 = 0x01 ROR 24
  512 = 0x02 ROR 24
1024 = 0x03 ROR 24
```

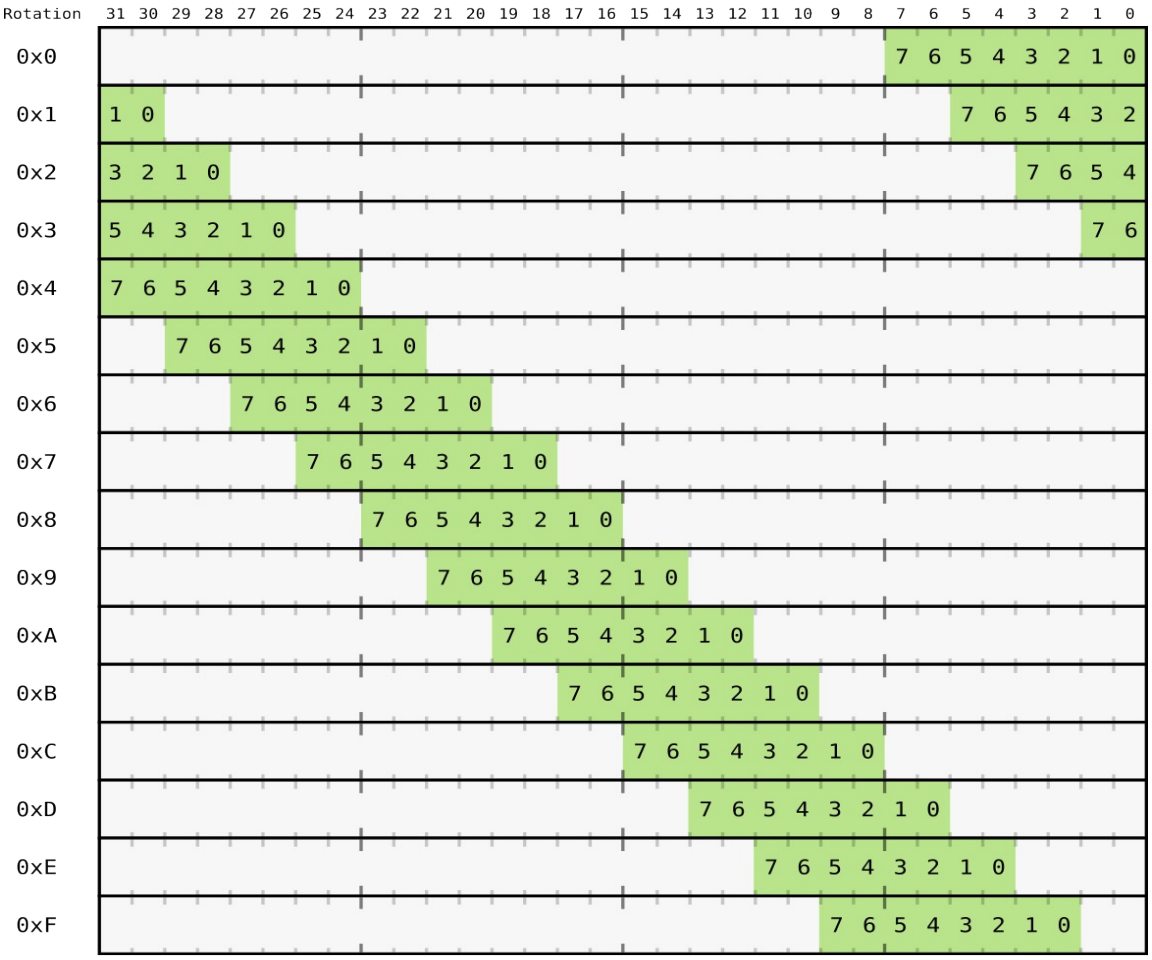

Кодирование ARM-32

B, BL

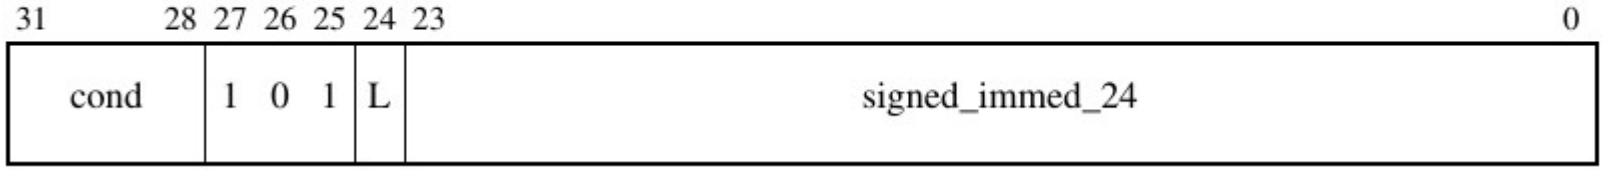

+/- 2^{23} - это +/- 8Мб

Переходы на метки

- В пределах +/- 8Мб - нет проблем
- Прыжок на далекую функцию - через "трамплин":
  - одна из причин использования PLT

Нарисовать на доске: как устроено размещение в памяти

Procedure Linkage Table

```
function@plt:
    add  ip, pc, #0
    add  ip, ip, #OFFSET_TO_TABLE_BEGIN
    ldr  pc, [ip, #OFFSET_TO_FUNCTION_INDEX]
```

Procedure Linkage Table

- Решает проблему "длинных" прыжков
- Позволяет размещать часть кода в заранее не известном месте адресного пространства

Показать вывод objdump -d

Про кодирование команд

- Расширения ARM:
  - Thumb -- 16 битные инструкции
  - Jazelle -- декодирование байткода Java

Про кодирование команд

- Регистровые машины выполнения
- Стековые машины выполнения

Байткод java

```
....

2: int someFunc(int a, int b){

3:      int c = 200*(a+b)

4:      return c;

5: }

....
```

```
int someFunc(int, int);
  descriptor: (II)I
  flags:
  Code:
    stack=3, locals=4,
args_size=3
     0: sipush 200
     3: iload_1
     4: iload_2
     5: iadd
     6: imul
     7: istore_3
     8: iload_3
     9: ireturn
LineNumberTable:
     line 3: 0
     line 4: 8
```

int c = 200*(a+b)

Пусть a = 10, b = 30

```
0: sipush 200
3: iload_1
4: iload_2
5: iadd
6: imul
7: istore_3
8: iload_3
9: ireturn
```

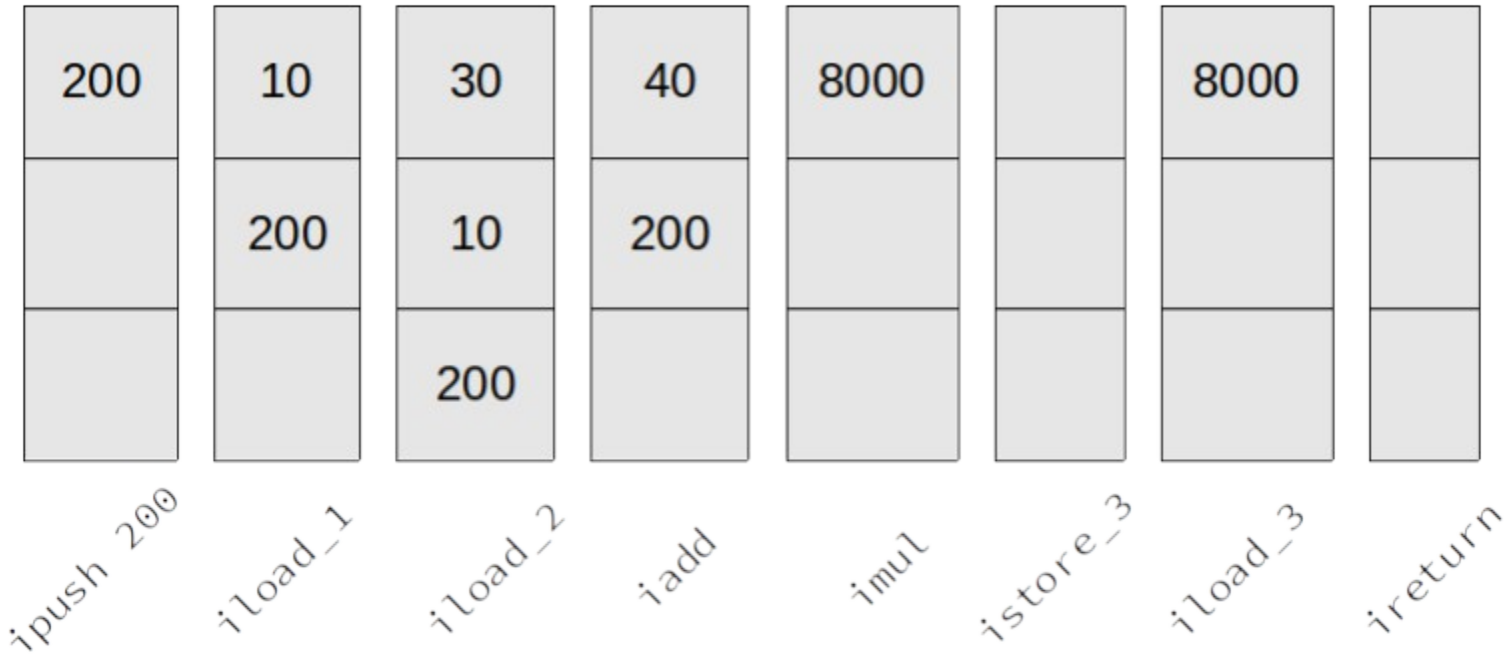

0	1	2	3
this	a	b	c

Уровни абстракции

- Высокоуровневый язык
- Intermediate Language:
  - bytecode (Java, CLI или PyPy)
  - LLVM - абстракция от ассемблеров разных архитектур
- [Язык ассемблера]
- Двоичный код

Зачем понимать кодирование команд

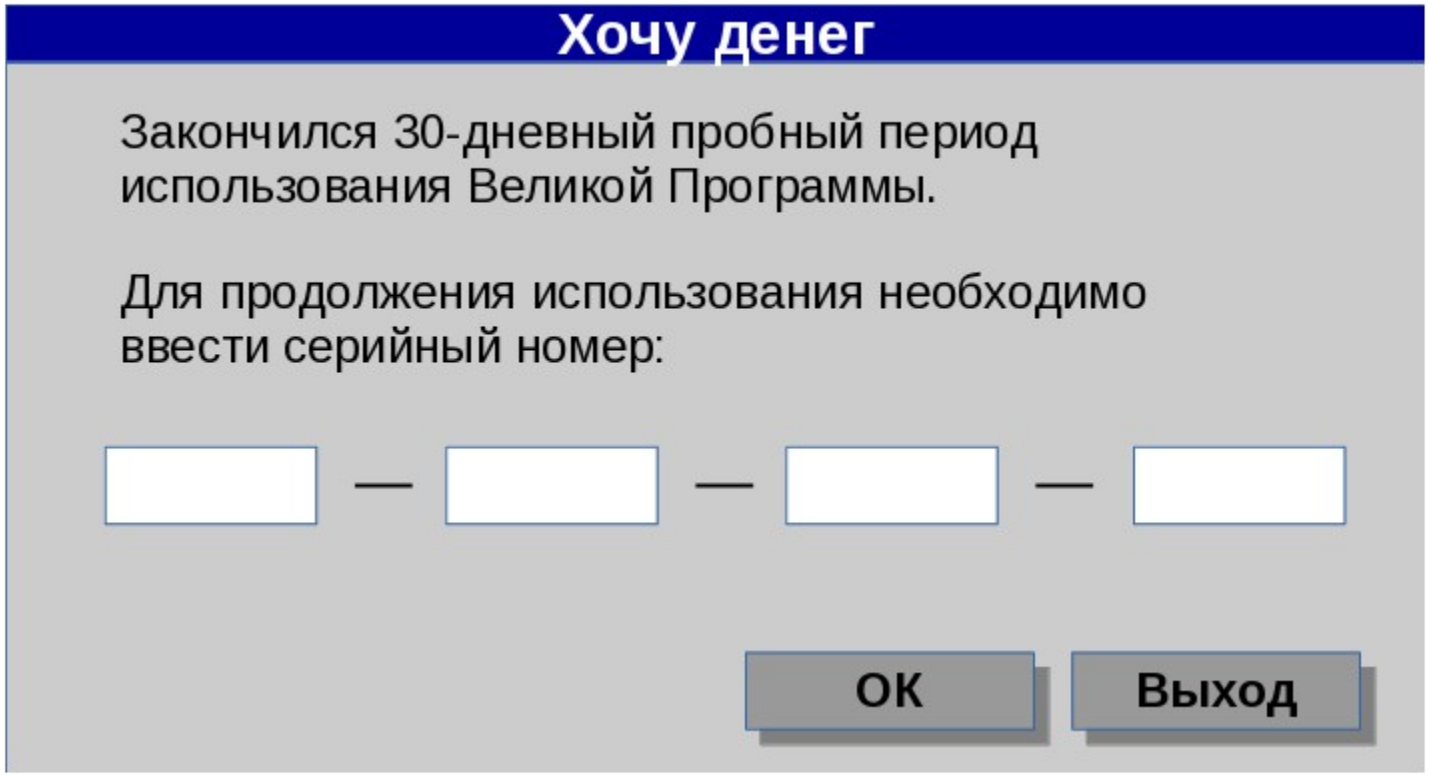

Уголовный кодекс РФ, глава 21 «Преступления против собственности»

Статья 159.6. Мошенничество в сфере компьютерной информации

1. Мошенничество в сфере компьютерной информации, то есть хищение чужого имущества или приобретение права на чужое имущество путем ввода, удаления, блокирования, модификации компьютерной информации либо иного вмешательства в функционирование средств хранения, обработки или передачи компьютерной информации или информационно-телекоммуникационных сетей, - наказывается штрафом в размере до ста двадцати тысяч рублей или в размере заработной платы или иного дохода осужденного за период до одного года, либо обязательными работами на срок до трехсот шестидесяти часов, либо исправительными работами на срок до одного года, либо ограничением свободы на срок до двух лет, либо принудительными работами на срок до двух лет, либо арестом на срок до четырех месяцев.

Как ломают

```
void TrialEndDialog_OkPressed()
{
  const char * sn =
Dialog_GetSerialNumber();
  if (CheckSerialNo(sn)) {
    ContinueLaunch();
  }
  else {
    ShowErrorMessage();
    ExitProgram();
  }
}
```

Как ломают

```
. . . . . .
01: callq    CheckSerialNo     ;; вызов [bool CheckSerialNo]
02: testb    $1, %al           ;; сравнение результата с 1
03: je       $05               ;; если OK, то переход к 05
04: jmp      $08               ;; переход к 08
05: movb$0, %al                ;; очистка регистра AL
06: callq    ContinueLaunch    ;; вызов [bool ContinueLaunch]
07: jmp      $0C               ;; переход к строке после if {}
08: movb$0, %al                ;; очистка регистра AL
09: callq    ShowErrorMessage  ;; вызов [void ShowErrorMessage]
0A: movb$0, %al                ;; очистка регистра AL
0B: callq    ExitProgram       ;; вызов [void ExitProgram]
. . . . . .
```

Как ломают

```
. . . . . .
01: callq   CheckSerialNo    ;; вызов [bool CheckSerialNo]
02: testb   $1, %al          ;; сравнение результата с 1
03: jejmp   $05              ;; если OK, то переход к 05
04: jmp     $08              ;; переход к 08
05: movb$0, %al              ;; очистка регистра AL
06: callq   ContinueLaunch   ;; вызов [bool ContinueLaunch]
07: jmp     $0C              ;; переход к строке после if {}
08: movb$0, %al              ;; очистка регистра AL
09: callq   ShowErrorMessage ;; вызов [void ShowErrorMessage]
0A: movb$0, %al              ;; очистка регистра AL
0B: callq   ExitProgram      ;; вызов [void ExitProgram]
. . . . . .
```